



**ОБРАЗОВАТЕЛЬНЫЙ
ЦЕНТР** МГТУ им. Н. Э. Баумана

ВЫПУСКНАЯ КВАЛИФИКАЦИОННАЯ РАБОТА по курсу «Data Science»

Тема: прогнозирование конечных свойств
новых материалов
(композиционных материалов)

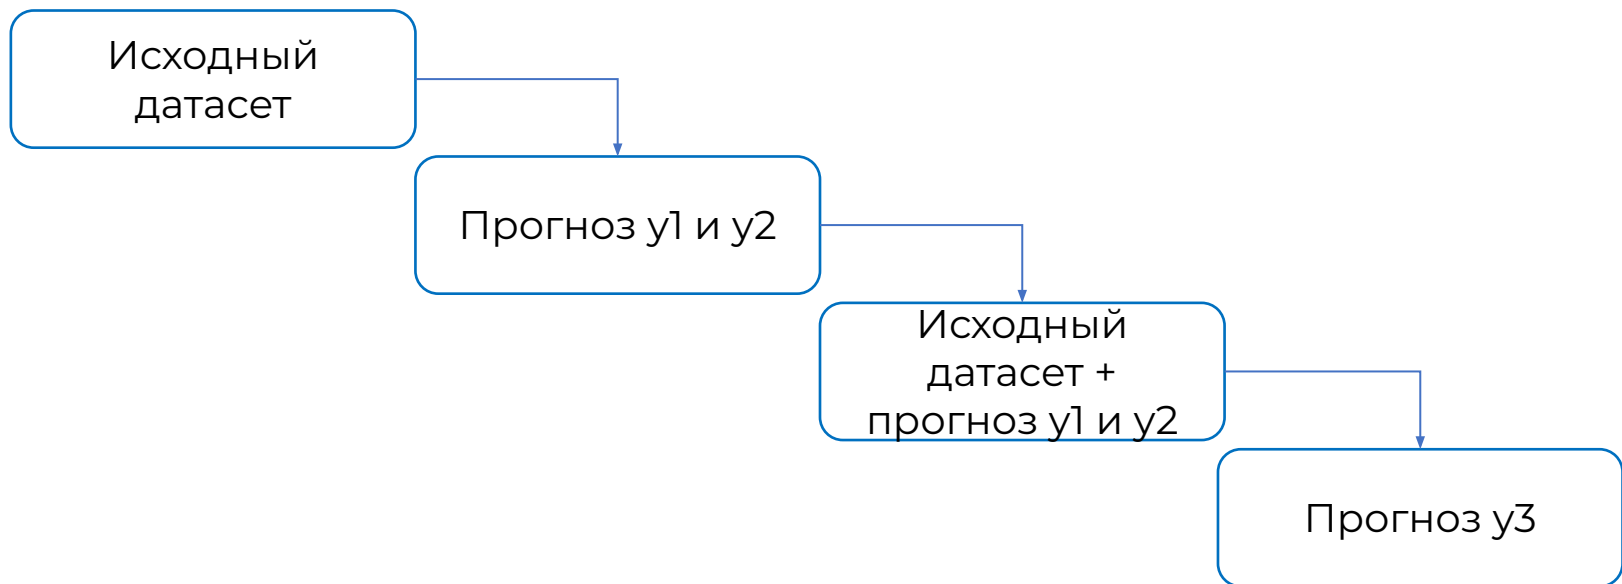
Н.А. Ядов

Цели и задачи работы

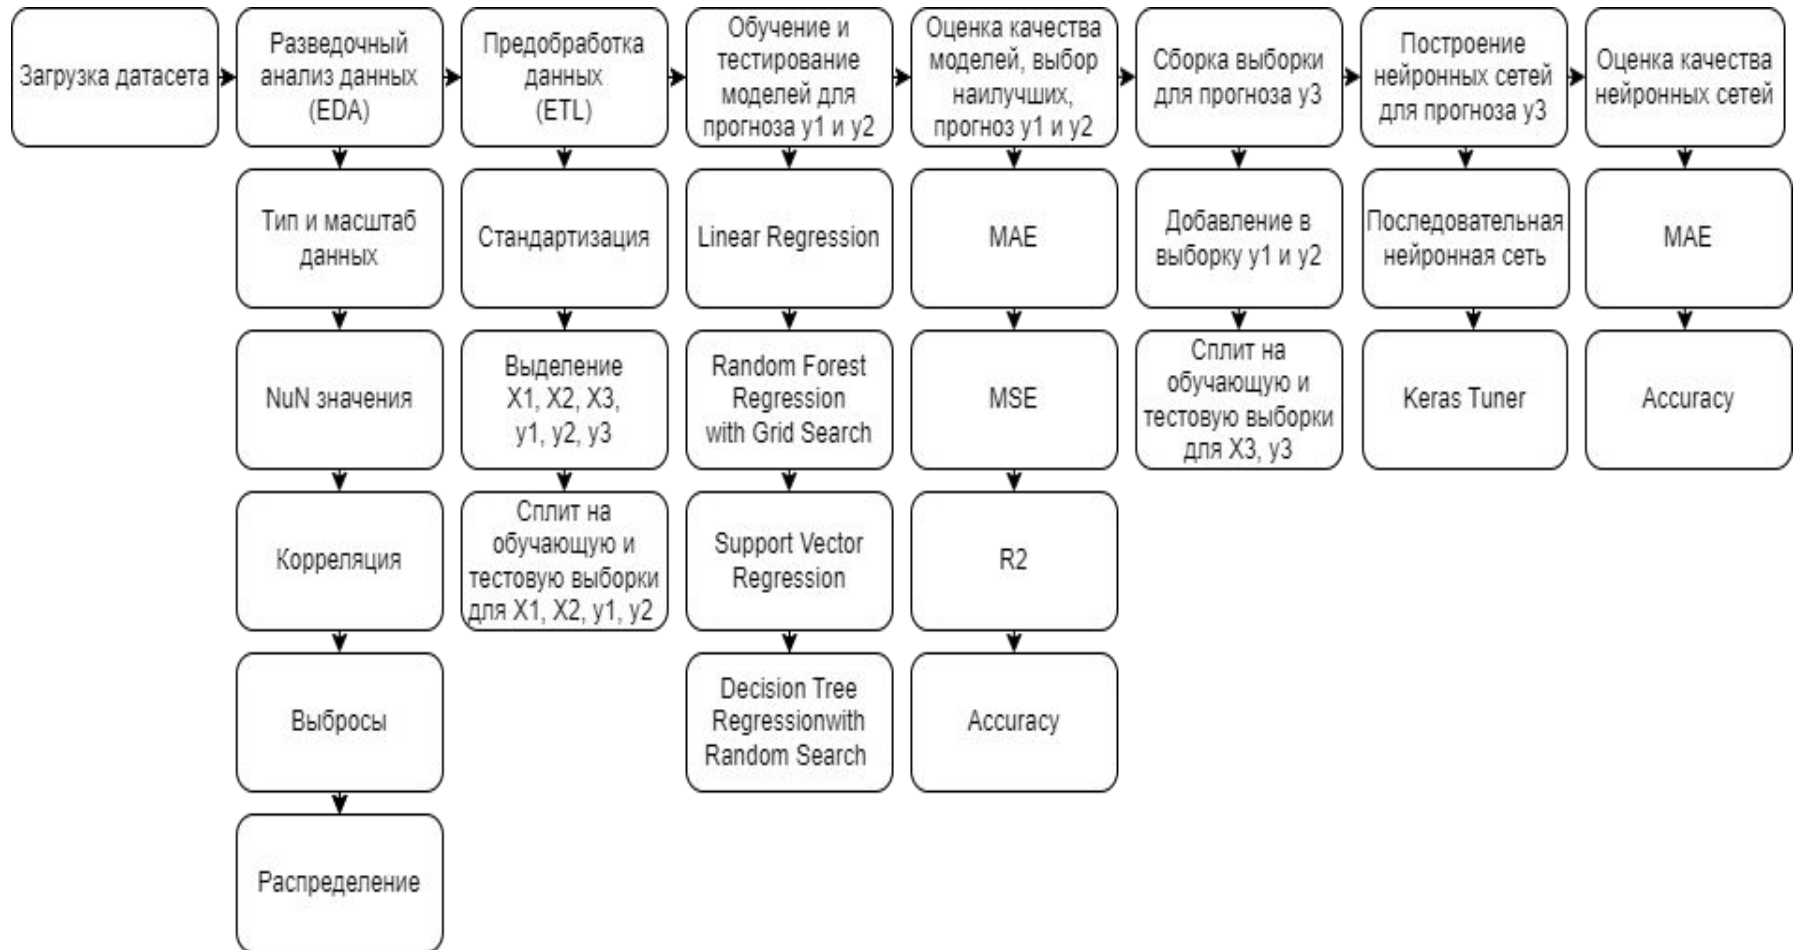
Прогнозирование ряда конечных свойств композиционных материалов:

- модуль упругости при растяжении – y_1 ;
- прочность при растяжении – y_2 ;
- соотношение матрица-наполнитель – y_3 .

Цели и задачи работы



Pipline




Exploratory Data Analysis


- отсутствуют пустые NuN значения;
- int64 и float64;
- отсутствие значимых корреляций;
- отсутствие выбросов;
- отсутствие значимых смещений в распределении.



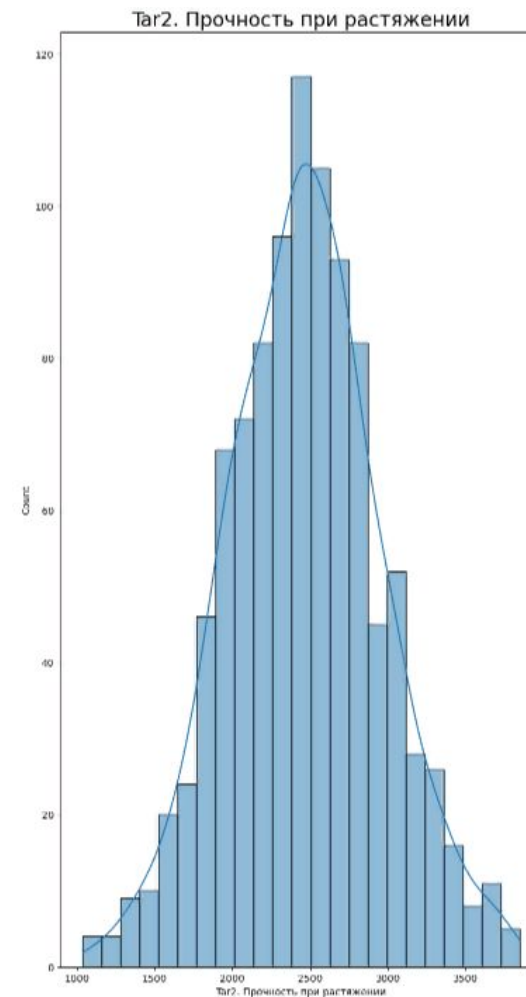


Матрица корреляций



Анализ выбросов boxplot, ящик с усами



Анализ распределения



Extract, Transformer, Load

- разделение на тестовые и обучающие выборки методом `train_test_split`

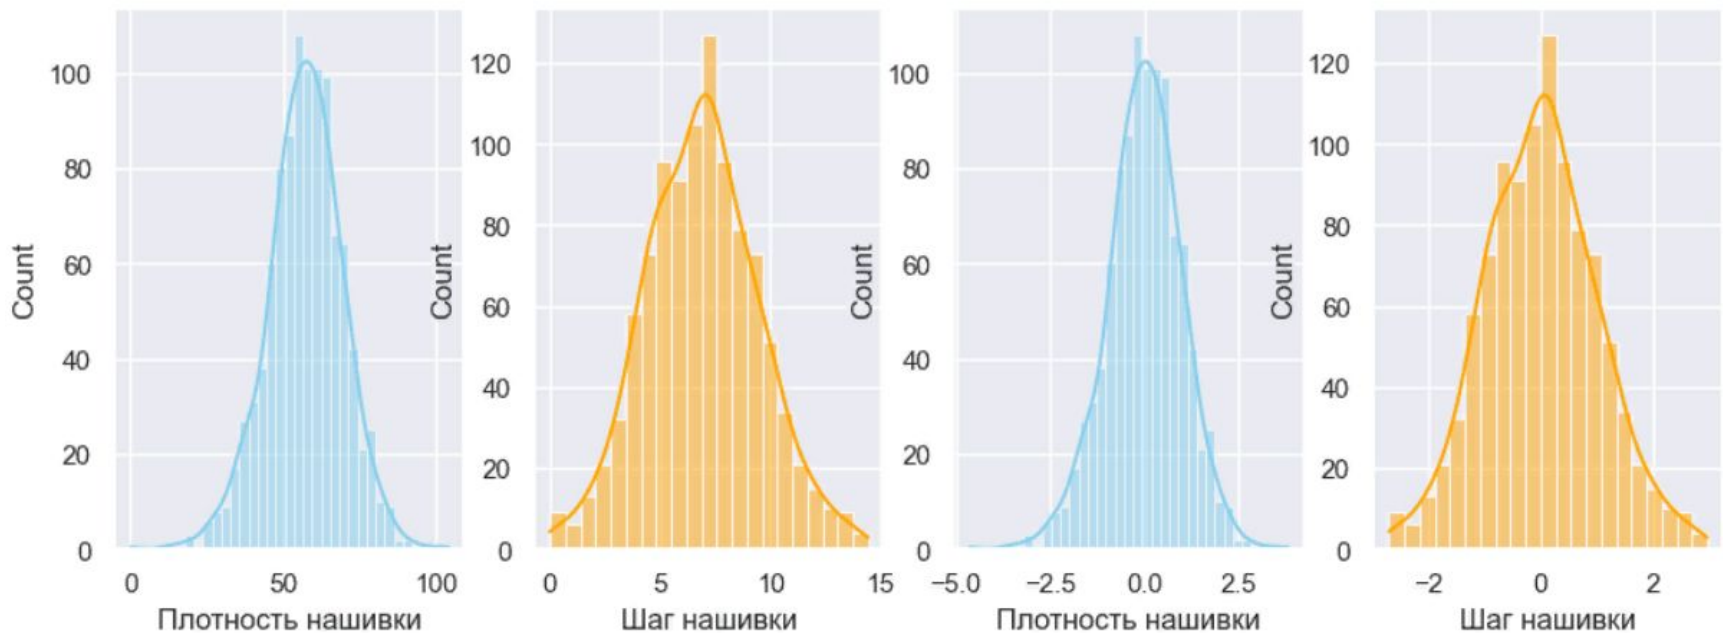
```
y1 = set_split['Tar1. Модуль упругости при растяжении']
y2 = set_split['Tar2. Прочность при растяжении']
y3 = set_split['Tar3. Соотношение матрица-наполнитель']

X1 = set_split.drop(['Tar3. Соотношение матрица-наполнитель', 'Tar1. Модуль упругости при растяжении'], axis = 1)
X2 = set_split.drop(['Tar3. Соотношение матрица-наполнитель', 'Tar2. Прочность при растяжении'], axis = 1)
X3 = set_split.drop(['Tar1. Модуль упругости при растяжении', 'Tar2. Прочность при растяжении',
                    'Tar3. Соотношение матрица-наполнитель'], axis = 1)
```

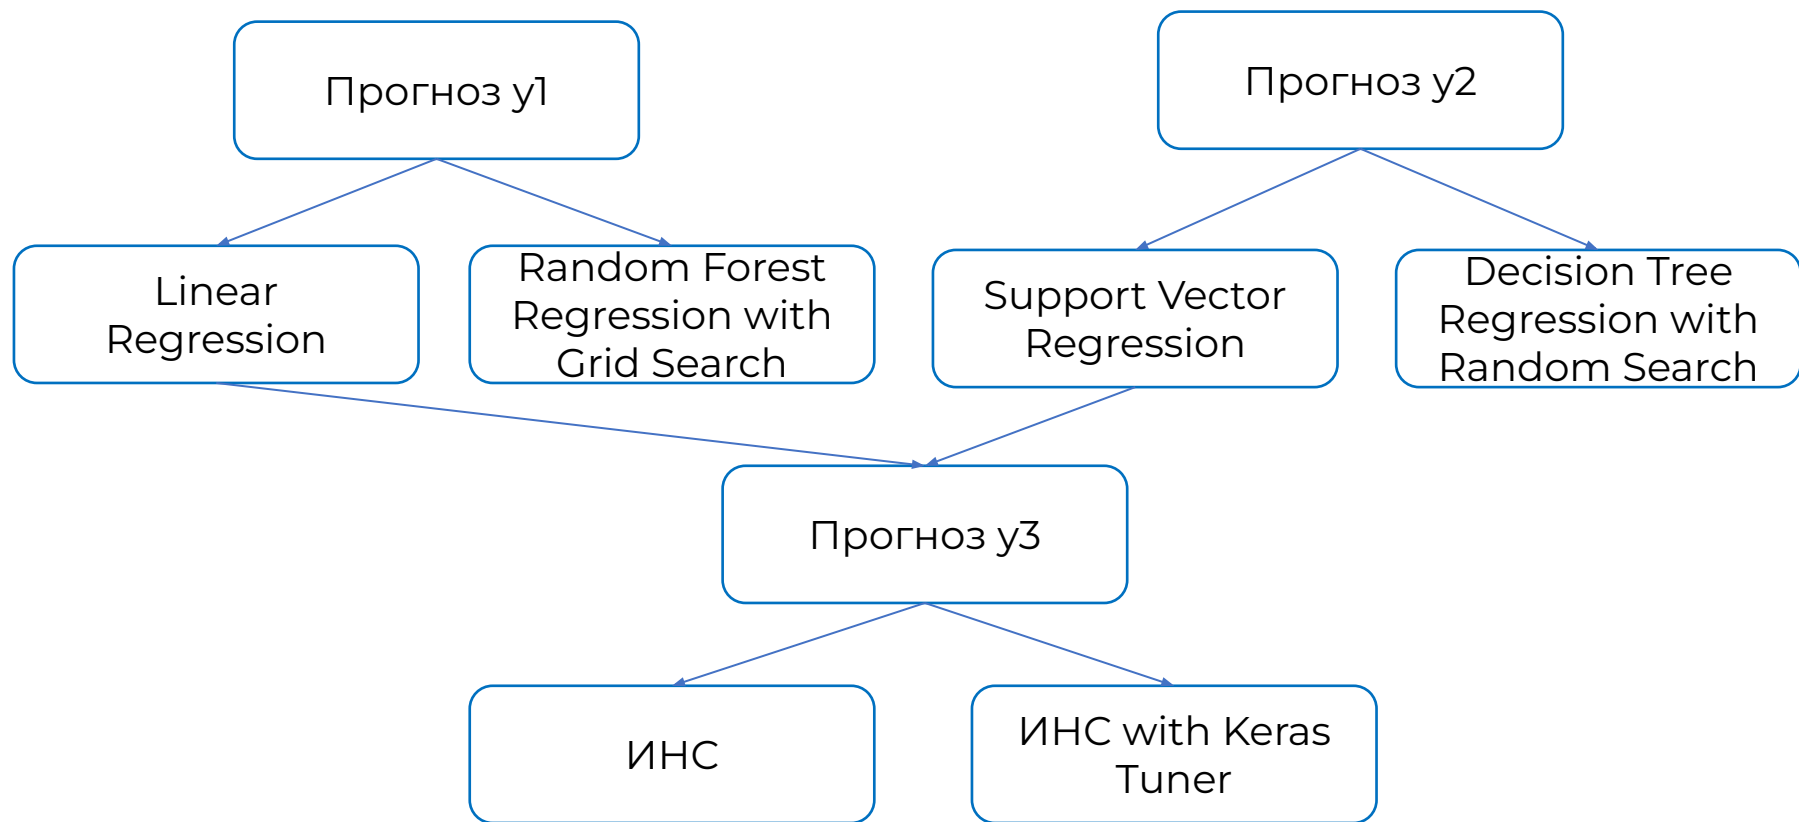
```
X1_train, X1_test, y1_train, y1_test = train_test_split(X1, y1, test_size=0.3, shuffle = True, random_state=42)
X2_train, X2_test, y2_train, y2_test = train_test_split(X2, y2, test_size=0.3, shuffle = True, random_state=42)
```

Extract, Transformer, Load

- масштабирование StandartScaler



Прогнозирование. Модели и ИНС



Прогнозирование. Модели

Target	Model	MAE	MSE	R2	accuracy
Tar1. Модуль упругости при растяжении	Linear Regression	2.557104	10.118841	-0.018564	96.526208
Tar1. Модуль упругости при растяжении	RandomForest Regression with Grid Search	2.565373	10.149580	-0.021658	96.514974
Tar2. Прочность при растяжении	Support Vector Regression	379.490730	224363.417124	-569632.206020	84.651504
Tar2. Прочность при растяжении	TDecision Tree Regressor with Random Search	380.952804	226299.789139	-577680.645878	84.592370

```

MAE_train: 2.4613192952688316
MAE_test: 2.5571035925102468
MSE_train: 9.379429049269936
MSE_test: 10.118841188115416
r2_train: 0.02063112061922867
r2_test: -0.018563613121253653
Точность модели на трейне: 96.63787934635941
Точность модели на тесте: 96.52620775333057
    
```

Прогнозирование. ИНС

```
model_ns = tf.keras.models.Sequential()  
model_ns.add(tf.keras.Input(shape=(12,)))  
model_ns.add(Dense(1, input_dim=12, activation='linear'))  
  
model_ns.compile(  
    optimizer=tf.keras.optimizers.Adam(0.001),  
    loss='mean_absolute_error')
```

```
model_ns.summary()
```

Model: "sequential_14"

Layer (type)	Output Shape	Param #
=====	=====	=====
dense_16 (Dense)	(None, 1)	13
=====	=====	=====


Total params: 13

Trainable params: 13

Non-trainable params: 0

Прогнозирование. ИНС

```
history_ns = model_ns.fit(  
    X3_train,  
    y3_train,  
    epochs=300,  
    verbose=0,  
    validation_split = 0.2)
```



```
mae_ns = model_ns.evaluate(X3_test, y3_test, verbose=0)  
print('MAE:', mae_ns)  
print('Точность модели:', 100 - (mae_ns / y3_test.mean() * 100))
```

MAE: 0.7650960087776184
Точность модели: 74.07735800719789

```
mae_ns = model_ns.evaluate(X3_test, y3_test, verbose=0)  
print('MAE:', mae_ns)  
print('Точность модели:', 100 - (mae_ns / y3_test.mean() * 100))
```

MAE: 0.7639831304550171
Точность модели: 74.11506405455322

Прогнозирование. ИНС with Keras Tuner

```
def tuner_model(hp):
    model = Sequential()

    activation_choice = hp.Choice('activation', values=['relu', 'sigmoid', 'tanh', 'elu', 'selu'])

    # сетка параметров входного слоя

    model.add(Dense(units=hp.Int('units_input',
                                min_value=12,
                                max_value=36,
                                step=2),
                    input_dim = X3_train.shape[1], #input_shape=(X3_train.shape[1])
                    activation = activation_choice))

    # сетка кол-ва слоев и их параметров:

    for i in range(hp.Int('num_layers', 2, 5)):
        model.add(layers.Dense(units=hp.Int('units_' + str(i),
                                            min_value=32,
                                            max_value=128,
                                            step=32),
                                activation = activation_choice))

    model.add(Dense(1, activation='linear'))

    model.compile(
        optimizer=hp.Choice('optimizer', values=['adam', 'rmsprop', 'SGD']),
        loss='mean_absolute_error',
        metrics=['mean_absolute_error'])

    return model
```


Прогнозирование. ИНС with Keras Tuner

```
def tuner_model(hp):
    model = Sequential()

    activation_choice = hp.Choice('activation', values=['relu', 'sigmoid', 'tanh', 'elu', 'selu'])

    # сетка параметров входного слоя

    model.add(Dense(units=hp.Int('units_input',
                                min_value=12,
                                max_value=36,
                                step=2),
                    input_dim = X3_train.shape[1], #input_shape=(X3_train.shape[1])
                    activation = activation_choice))

    # сетка кол-ва слоев и их параметров:

    for i in range(hp.Int('num_layers', 2, 5)):
        model.add(layers.Dense(units=hp.Int('units_' + str(i),
                                            min_value=32,
                                            max_value=128,
                                            step=32),
                                activation = activation_choice))

    model.add(Dense(1, activation='linear'))

    model.compile(
        optimizer=hp.Choice('optimizer', values=['adam', 'rmsprop', 'SGD']),
        loss='mean_absolute_error',
        metrics=['mean_absolute_error'])

    return model
```


Прогнозирование. ИНС with Keras Tuner

```
best_model.summary() #архитектура лучшей модели
```

Model: "sequential"

Layer (type)	Output Shape	Param #
dense (Dense)	(None, 24)	312
dense_1 (Dense)	(None, 32)	800
dense_2 (Dense)	(None, 96)	3168
dense_3 (Dense)	(None, 96)	9312
dense_4 (Dense)	(None, 32)	3104
dense_5 (Dense)	(None, 1)	33

Total params: 16,729

Trainable params: 16,729

Non-trainable params: 0

```
best_model = tuner.get_best_models(num_models=1)[0] #получаем лучшую модель
```

```
loss, mae = best_model.evaluate(X3_test, y3_test) #метрики лучшей модели
```

```
print('Точность сети:', 100 - (mae / y3_test.mean() * 100))
```

10/10 [=====] - 0s 3ms/step - loss: 0.7552 - mean_absolute_error: 0.7552

Точность сети: 74.41249370205179

Flask-приложение



Предсказание значений модуля упругости при растяжении

Введите значения известных параметров:

Плотность, кг/м3	Модуль упругости, ГПа	Количество отвердителя, л	Содержание эпоксидных г	Температура вспышки, С_	Поверхностная плотность	Прочность при растяжени
Потребление смолы, г/м2	Угол нашивки, град	Шаг нашивки	Плотность нашивки	Predict		



Предсказание значений модуля упругости при растяжении

Введите значения известных параметров:

5	3	5	7	4	4	4
43	4	11	4	Predict		

Модуль упругости при растяжении, ГПа :76.84

```
test = np.array([5, 3, 5, 7, 4, 4, 4, 43, 4, 11, 4])
test = test.reshape(1, -1)
test_pred = model.predict(test)
test_pred
```

```
array([76.84437407])
```

Спасибо за внимание!